Université de Caen Normandie

IUT Grand Ouest Normandie

Pôle de Caen

Bachelor Universitaire de Technologie

Science des Données

Troisième année

SAÉ 6.EMS.01 : Modélisation statistique pour les données complexes et le Big Data

---

Modélisation statistique pour la prédiction du risque de cancer dans la cohorte AGRICAN

Auteurs

Giovanni BINAZON

Balla TRAORE

Année universitaire 2025-2026

SOMMAIRE

1 Introduction **3**

1.1 Contexte scientifique 3

1.2 Présentation de la cohorte AGRICAN 3

1.3 Construction des variables et problématique 3

1.4 Démarche méthodologique 3

2 Données et prétraitement **4**

2.1 Description de la base de données 4

2.2 Description univariée 4

2.3 Détection des valeurs aberrantes 6

2.4 Imputation des données manquantes 6

2.5 Analyse exploratoire multivariée 7

3 Présélection des variables **8**

3.1 Principe de la méthode 8

3.2 Variables retenues 8

4 Modélisation **9**

4.1 Stratégie de validation 9

4.2 Modèles linéaires 9

4.3 Modèles à base d'arbres 10

4.4 Réseaux de neurones 11

4.5 Comparaison globale 12

5 Conclusion **14**

6 Annexe A : Principales fonctions et méthodes utilisées **15**

1 | Introduction

1.1 | Contexte scientifique

L'agriculture constitue un secteur d'activité essentiel, mais elle expose les travailleurs à une grande diversité de facteurs professionnels et environnementaux susceptibles d'influencer leur état de santé. Ces expositions peuvent être chimiques, en lien notamment avec l'usage de produits phytosanitaires, de solvants ou de carburants, biologiques, à travers le contact avec des micro-organismes ou encore physiques, du fait de l'exposition prolongée au rayonnement solaire et à certaines contraintes du travail en extérieur.

La spécificité du monde agricole réside dans la multiplicité et la combinaison de ces expositions au cours de la carrière. Un même individu peut exercer différentes activités d'élevage et de culture, simultanément ou successivement, ce qui conduit à des profils professionnels complexes, hétérogènes et potentiellement corrélés. Dans ce contexte, l'étude statistique du lien entre pratiques agricoles et survenue d'une pathologie nécessite des outils capables de traiter des variables nombreuses, peu symétriques, souvent clairsemées et parfois redondantes. Notre objectif, au travers de ce projet, fut de déterminer les principaux facteurs ou activitées dont la pratique pourrait influencer significativement le risque de développer certaines pathologies chez les travailleurs agricoles, et, dans un second temps, de créer et comparer des modèles de prédiction afin d'identifier les approches les plus performantes pour estimer ce risque à partir des données disponibles.

1.2 | Présentation de la cohorte AGRICAN

La cohorte AGRICAN (AGRIculture et CANcer) est une cohorte prospective française constituée d'affiliés au régime agricole de la Mutualité Sociale Agricole (MSA). Son objectif est d'étudier l'incidence des cancers et, plus largement, les effets des expositions professionnelles agricoles sur la santé.

Dans le cadre de ce projet, nous utilisons une sous-cohorte décrivant les activités agricoles exercées au cours de la carrière professionnelle. Les informations disponibles permettent de reconstruire des profils d'activité à partir de ratios de pratique, reflétant la part relative du temps consacrée à chaque type d'élevage ou de culture.

1.3 | Construction des variables et problématique

Pour chacune des 18 activités agricoles retenues, un ratio de pratique a été calculé entre la durée de pratique de l'activité et la durée totale de la carrière professionnelle :

$$\text{Ratio} = \frac{\text{durée de pratique de l'activité}}{\text{durée totale de la carrière professionnelle}} \tag{1}$$

Ces ratios constituent les variables explicatives qui nous permettra de construire des modèles de prédictions. La variable cible est binaire et indique la présence (1) ou l'absence (0) de la maladie étudiée.

La problématique centrale de ce travail est la suivante :

Dans quelle mesure les profils de carrière agricole, décrits par les ratios de pratique des différentes activités, permettent-ils de prédire la présence de la maladie étudiée ?

1.4 | Démarche méthodologique

Afin de répondre à cette question, nous avons adopté une démarche progressive articulée autour de quatre étapes : un prétraitement des données comprenant la description univariée, la détection des valeurs hors domaine et l'exploration des corrélations par ACP ; une imputation des données manquantes après remplacement des valeurs aberrantes par des valeurs manquantes ; une présélection robuste des variables par Bootstrap et régression logistique avec sélection pas à pas selon l'AIC ; enfin, une comparaison de plusieurs approches de modélisation, allant de la régression logistique aux méthodes d'ensemble, aux arbres et aux réseaux de neurones.

Les performances des modèles sont évaluées à l'aide de la sensibilité et de la spécificité, sur 40 découpages aléatoires apprentissage/test, afin d'apprécier à la fois le niveau moyen de performance et sa stabilité.

2 | Données et prétraitement

2.1 | Description de la base de données

La base de données analysée correspond à une sous-cohorte issue de l'étude AGRICAN. Elle comprend 12 052 individus et 19 variables : 18 variables explicatives quantitatives correspondant aux ratios de pratique des activités agricoles, ainsi qu'une variable cible binaire indiquant la présence ou l'absence de la maladie étudiée.

Les variables explicatives représentent les proportions de carrière consacrées à différentes activités d'élevage et de culture (bovins, moutons/chèvres, cochons, chevaux, volailles, prairies, vigne, maïs, blé, etc.).

En théorie, ces ratios doivent vérifier :

$$0 \leq \text{Ratio} \leq 1$$

Une valeur égale à 0 signifie que l'activité n'a jamais été exercée, tandis qu'une valeur proche de 1 traduit une spécialisation quasi exclusive dans une activité donnée.

	RIBov Ratio de Pratique de Bovin	RIMou Ratio de Pratique de Moutons/Chèvre	RICoc Ratio de Pratique de Cochon	RIChe Ratio de Pratique de Chevaux	RIVol Ratio de Pratique de Volaille	RIPrai Ratio de Pratique de Prairies
1	1.0000000	0.0000000	0.00000000	0.0000000	0.00000000	1.00000000
2	0.8461538	0.0000000	0.00000000	0.0000000	0.00000000	0.00000000
3	0.0000000	0.0000000	0.00000000	0.0000000	0.00000000	0.00000000
4	1.0000000	0.0000000	0.00000000	0.0000000	0.00000000	1.00000000
5	1.0000000	1.0000000	0.33333333	0.4666667	1.00000000	0.00000000
6	0.0000000	0.0000000	0.00000000	0.0000000	0.00000000	0.00000000
7	0.0000000	0.0000000	0.00000000	0.0000000	0.00000000	0.00000000
8	1.0000000	0.0000000	0.00000000	0.0000000	0.00000000	0.00000000
9	1.0000000	0.0000000	0.00000000	0.0000000	0.00000000	0.00000000
10	1.0000000	0.0000000	0.30000000	0.3000000	0.80000000	0.00000000

Fig. 1 - Extrait des premières observations de la base de données

La figure 1 présente un extrait des premières lignes de la base. On y observe la structure tabulaire des données ainsi que la nature quantitative des variables explicatives, définies comme des ratios de pratique des différentes activités agricoles au cours de la carrière.

2.2 | Description univariée

Avant toute transformation des données, une description univariée a été réalisée afin de caractériser les distributions des variables, la fréquence des valeurs nulles ainsi que la présence éventuelle de valeurs hors domaine.

Le tableau de synthèse présente, pour chaque variable, l'effectif observé, la moyenne, l'écart-type, la médiane, les bornes extrêmes, la proportion de valeurs non nulles et la proportion de valeurs strictement supérieures à 1.

Description univariée des variables quantitatives

Ratios de pratiques agricoles

Variable	Effectif	Moyenne (Écart-type)	Médiane	Min	Max	% non nuls	Nb aberrantes	% aberrantes
Bovin	12052	0.6046 (0.4379)	0.8400	0.0000	2.1262	72.7	18	0.15
Moutons / Chèvres	12052	0.0569 (0.2071)	0.0000	0.0000	2.1195	9.1	26	0.22
Cochon	12052	0.1486 (0.3137)	0.0000	0.0000	2.0692	23.4	26	0.22
Chevaux	12052	0.1449 (0.3102)	0.0000	0.0000	2.1913	24.5	27	0.22
Volaille	12052	0.1511 (0.3322)	0.0000	0.0000	2.1143	20.2	24	0.20
Prairies	12052	0.2168 (0.3931)	0.0000	0.0000	2.1909	24.9	28	0.23
Vigne	12052	0.2746 (0.4278)	0.0000	0.0000	2.1963	31.6	33	0.27
Maïs	12052	0.0679 (0.2299)	0.0000	0.0000	1.1699	9.0	17	0.14
Blé	12052	0.2510 (0.4085)	0.0000	0.0000	2.1388	29.6	30	0.25
Pois fourragers	12052	0.0138 (0.1059)	0.0000	0.0000	1.1918	2.1	26	0.22
Betteraves sucrières	12052	0.0269 (0.1533)	0.0000	0.0000	1.5354	3.4	34	0.28
Tournesol	12052	0.0090 (0.0881)	0.0000	0.0000	1.1953	1.3	30	0.25
Colza	12052	0.0123 (0.1012)	0.0000	0.0000	1.9338	1.9	20	0.17
Tabac	12052	0.0512 (0.1938)	0.0000	0.0000	1.7454	8.7	19	0.16
Arboriculture	12052	0.0745 (0.2466)	0.0000	0.0000	2.1050	9.8	32	0.27
Pomme de terre	12052	0.1921 (0.3718)	0.0000	0.0000	2.1993	24.1	34	0.28
Légumes plein champ	12052	0.0651 (0.2303)	0.0000	0.0000	2.0346	8.9	20	0.17
Cultures sous serres	12052	0.0271 (0.1489)	0.0000	0.0000	1.1859	3.9	19	0.16

Lecture du tableau :
% *non nuls* = proportion d'observations strictement supérieures à 0.
% *aberrantes* = proportion de ratios strictement supérieurs à 1.

Fig. 2 - Description univariée des variables quantitatives

La figure 2 met en évidence une forte hétérogénéité dans la fréquence de pratique des différentes activités agricoles. Certaines activités apparaissent relativement fréquentes, comme l'élevage bovin pratiqué par environ **72,7%** des individus, tandis que d'autres activités, comme le tournesol ou le colza, sont très peu représentées dans la cohorte.

La majorité des variables présentent une médiane égale à zéro, ce qui indique que plus de la moitié des individus n'exercent pas ces activités. Cette caractéristique traduit une forte spécialisation des exploitations agricoles.

Le tableau met également en évidence la présence d'un faible nombre de valeurs aberrantes (ratios strictement supérieurs à 1), représentant moins de **0,3%** des observations selon les variables.

Les couleurs utilisées dans le tableau ont pour objectif de faciliter la lecture des résultats. Les dégradés permettent d'identifier visuellement les variables les plus fréquentes, les plus rares ainsi que celles présentant les proportions les plus élevées de valeurs hors domaine.

Afin de mieux visualiser la forme des distributions, des courbes de densité ont également été tracées pour l'ensemble des variables de ratios.

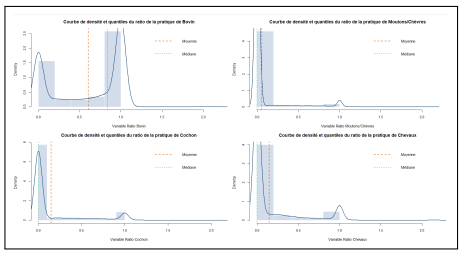

(a) Ratios d'activités d'élevage

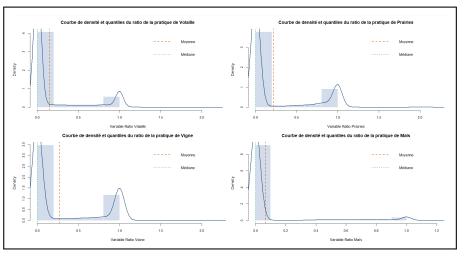

(b) Ratios de cultures agricoles

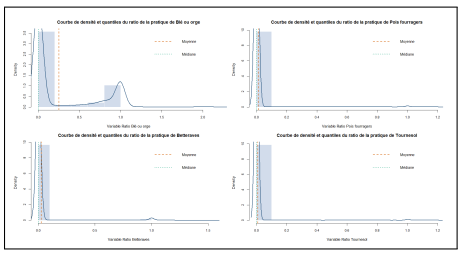

(c) Cultures céréalières et industrielles

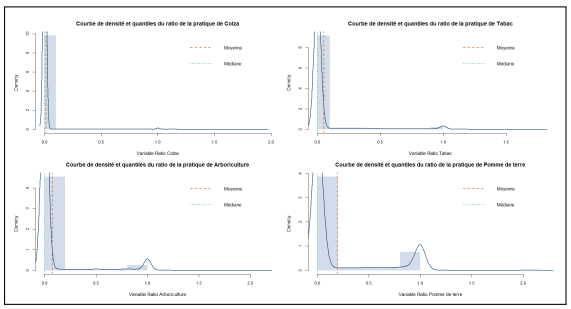

(d) Cultures spécialisées

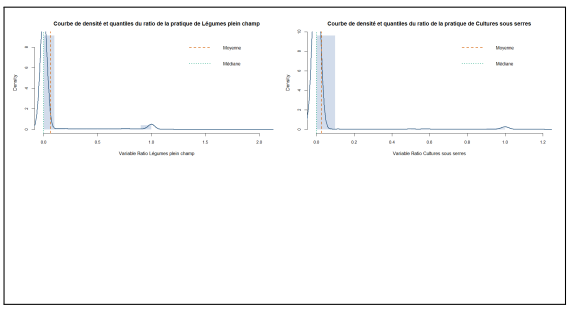

(e) Cultures légumières et sous serres

Fig. 3 - Courbes de densité des ratios de pratique agricole

La figure 3 présente les distributions des ratios de pratique agricole à l'aide d'histogrammes et de courbes de densité. Les lignes verticales indiquent respectivement la moyenne et la médiane de chaque variable.

On observe globalement une forte concentration des observations au voisinage de 0, ce qui signifie qu'une grande partie des individus n'exerce pas certaines activités agricoles. À l'inverse, certaines distributions présentent également une accumulation de valeurs proches de 1, traduisant l'existence de profils professionnels spécialisés pour certains agriculteurs.

Les distributions apparaissent fortement asymétriques à droite, ce qui est caractéristique de variables représentant des proportions d'activité. La présence ponctuelle de valeurs supérieures à 1 confirme également l'existence de valeurs hors domaine nécessitant un traitement avant la phase de modélisation.

2.3 | Détection des valeurs aberrantes

Dans ce travail, les valeurs aberrantes n'ont pas été définies à l'aide d'une règle statistique classique (par exemple basée sur l'écart interquartile), mais à partir d'une règle de cohérence métier.

En effet, les variables étudiées étant des ratios de carrière, toute valeur strictement supérieure à 1 est théoriquement impossible. Une telle valeur signifie que la durée déclarée pour une activité dépasse la durée totale de la carrière professionnelle.

Ainsi, pour chaque variable explicative, les observations vérifiant :

$$\text{Ratio} > 1$$

ont été identifiées, exportées dans des fichiers de contrôle puis remplacées par des valeurs manquantes.

Cette stratégie présente plusieurs avantages :

— conserver l'ensemble des individus dans la base de données ;
— éviter la suppression d'observations complètes ;
— corriger les incohérences avant la phase de modélisation.

2.4 | Imputation des données manquantes

Après transformation des valeurs aberrantes en valeurs manquantes, une imputation a été réalisée à l'aide de la méthode d'imputation par Analyse en Composantes Principales via la fonction `imputePCA()` du package `missMDA`.

Cette approche est particulièrement adaptée dans un contexte multivarié car elle exploite la structure de corrélation entre les variables quantitatives afin de reconstruire les valeurs manquantes de manière cohérente. Contrairement à une imputation simple par moyenne ou médiane, cette méthode permet de préserver les relations existantes entre variables et de limiter la perte d'information.

2.5 | Analyse exploratoire multivariée

Afin d'examiner les relations entre les différentes pratiques agricoles, une analyse exploratoire multivariée a été réalisée à l'aide d'une Analyse en Composantes Principales (ACP). Cette méthode permet de synthétiser l'information contenue dans un ensemble de variables quantitatives potentiellement corrélées en un nombre réduit de dimensions tout en conservant au maximum la variabilité des données.

L'ACP a été appliquée aux variables de ratios de pratique des différentes activités agricoles après imputation des valeurs manquantes et centrage-réduction des variables. Les deux premières dimensions expliquent respectivement **15,4 %** et **9,6 %** de la variance totale, soit environ **25 %** de la variance cumulée.

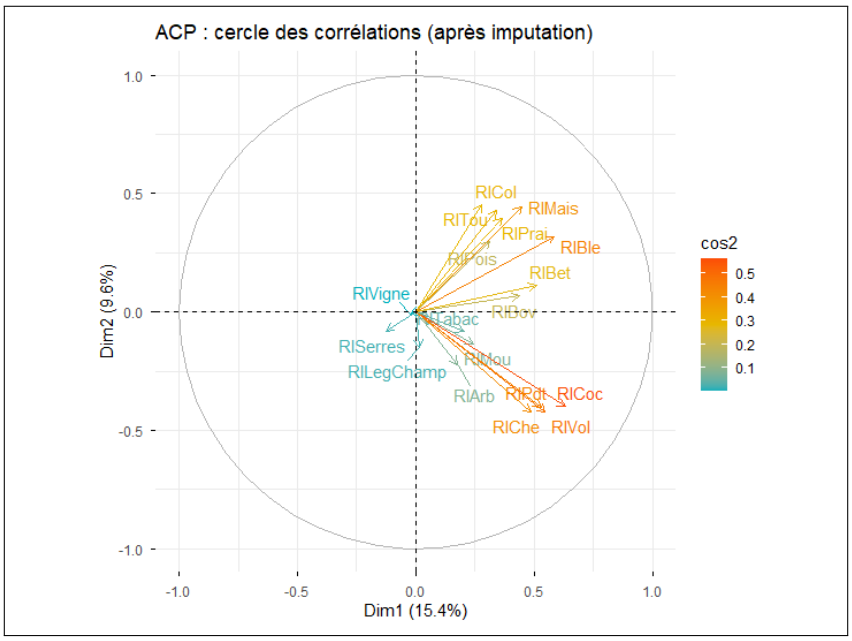

Fig. 4 - Cercle des corrélations issu de l'Analyse en Composantes Principales

Le cercle des corrélations représente la projection des variables sur le plan défini par les deux premières composantes principales. Les variables proches correspondent à des activités agricoles souvent pratiquées conjointement, tandis que des variables situées dans des directions opposées traduisent des spécialisations agricoles différentes.

La coloration des variables correspond à leur qualité de représentation sur le plan factoriel (mesurée par le cosinus carré, noté $\cos^2$). Les variables les plus colorées sont celles qui contribuent le plus aux deux premières dimensions de l'ACP.

Cette analyse exploratoire met en évidence l'existence de relations entre certaines pratiques agricoles et confirme l'intérêt d'une étape de présélection de variables avant la phase de modélisation.

3 | Présélection des variables

3.1 | Principe de la méthode

La présence de nombreuses variables explicatives peut entraîner une instabilité des estimations et augmenter la variance des modèles prédictifs, notamment lorsque certaines variables sont corrélées entre elles. Afin de limiter ce risque et de retenir les variables les plus pertinentes pour la prédiction, une procédure de sélection robuste a été mise en place.

La méthode repose sur un **ré-échantillonnage Bootstrap** de la base de données combiné à une sélection automatique des variables dans un modèle de régression logistique.

Plus précisément, la procédure est la suivante :

— génération de **50 échantillons Bootstrap** à partir de la base de données initiale ;
— ajustement d'un **modèle de régression logistique complet** sur chaque échantillon ;
— application d'une procédure de sélection **Stepwise** fondée sur le critère d'information d'Akaike (AIC) ;
— enregistrement des variables sélectionnées à chaque itération.

Pour chaque variable explicative, la **fréquence de sélection** est ensuite calculée comme la proportion d'échantillons Bootstrap dans lesquels la variable est retenue par la procédure Stepwise. Cette approche permet d'identifier les variables les plus **stables et robustes** vis-à-vis des fluctuations d'échantillonnage.

3.2 | Variables retenues

Les cinq variables présentant les fréquences de sélection les plus élevées ont été retenues pour la phase de modélisation.

Tableau 1 – Variables retenues après procédure de sélection Bootstrap

Variable	Fréquence de sélection
RIMou	1.00
RICoc	1.00
RIVol	1.00
RIPrai	1.00
RIPois	0.64

On observe que quatre variables sont sélectionnées dans **100 % des échantillons Bootstrap** : **RIMou**, **RICoc**, **RIVol** et **RIPrai**. La variable **RIPois** est retenue dans **64 %** des cas.

Ces variables apparaissent donc comme les plus **robustes** dans le processus de sélection et ont été conservées pour l'ensemble des modèles prédictifs étudiés dans la suite du travail.

4 | Modélisation

4.1 | Stratégie de validation

Afin d'évaluer de manière robuste les performances des différents modèles, une procédure de validation répétée a été mise en œuvre.

La base de données a été divisée aléatoirement en 40 couples apprentissage/test, avec :

— 70 % des observations utilisées pour l'apprentissage des modèles ;

— 30 % des observations utilisées pour l'évaluation des performances.

Cette procédure de validation répétée permet de réduire l'influence d'un découpage particulier de l'échantillon et d'obtenir une estimation plus stable des performances des modèles.

Les indicateurs retenus pour évaluer les performances sont :

— la **sensibilité**, correspondant à la proportion d'individus malades correctement identifiés par le modèle ;

— la **spécificité**, correspondant à la proportion d'individus non malades correctement classés.

L'utilisation de ces deux indicateurs permet d'évaluer simultanément la capacité du modèle à détecter les cas positifs tout en limitant les erreurs de classification chez les individus non malades.

Les performances présentées dans la suite correspondent aux distributions obtenues sur les 40 découpages aléatoires.

4.2 | Modèles linéaires

Quatre approches ont été comparées dans cette première famille de modèles :

— la régression logistique classique ;

— le bagging (Bootstrap Aggregating) ;

— le boosting (AdaBoost.M1) ;

— une stratégie de préclassification suivie d'une régression logistique par cluster.

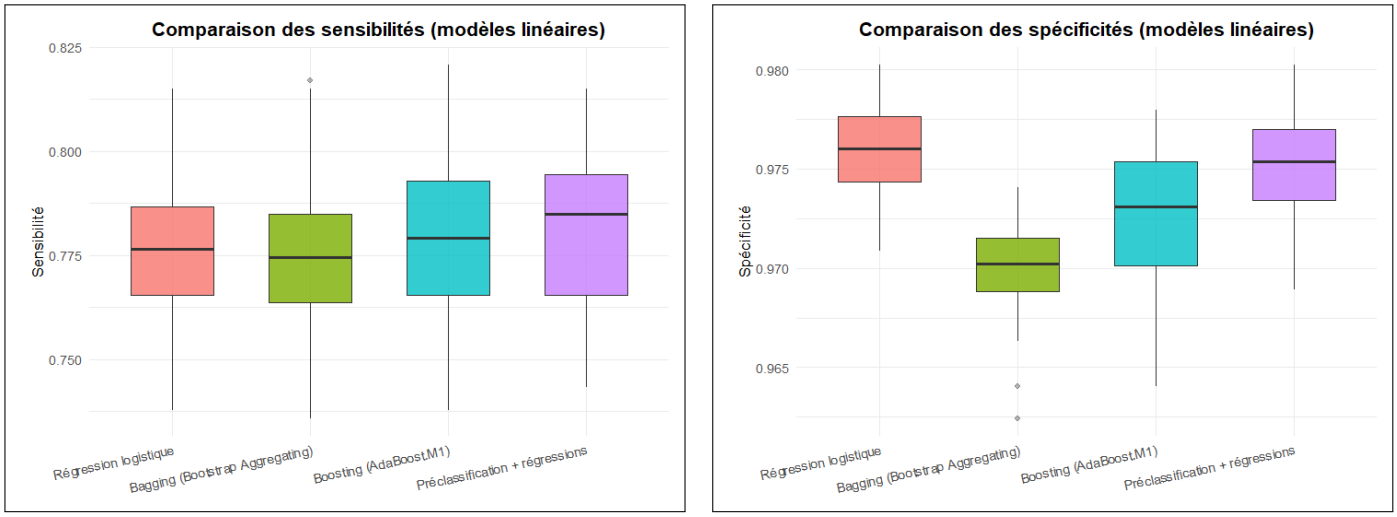

(a) Sensibilité (b) Spécificité

Fig. 5 - Comparaison des performances des modèles linéaires

Les boxplots présentés sur la figure 5 illustrent la distribution des performances obtenues sur les 40 découpages apprentissage/test.

Les résultats montrent des performances globalement proches entre les différentes approches linéaires. La sensibilité moyenne varie approximativement entre **0,775** et **0,781**, tandis que la spécificité moyenne se situe entre **0,970** et **0,976**.

La stratégie de préclassification associée à des régressions logistiques par cluster obtient la meilleure sensibilité moyenne (**0,781**), tandis que la régression logistique classique présente la meilleure spécificité moyenne (**0,976**).

Ces écarts restent toutefois modérés, ce qui suggère que l'apport des méthodes d'ensemble et de la préclassification améliore légèrement la capacité de détection des cas malades, sans modifier fortement les performances globales.

Tableau récapitulatif des performances (modèles linéaires)

Modèle	Moyenne	Écart-type
sens_log	0.775802	0.018062
spec_log	0.975915	0.002296
sens_bag	0.774953	0.018487
spec_bag	0.969898	0.002641
sens_boost	0.778962	0.019851
spec_boost	0.972627	0.003174
sens_preclass	0.780755	0.018601
spec_preclass	0.974992	0.002554

Fig. 6 - Tableau récapitulatif des performances des modèles linéaires

Dans les tableaux récapitulatifs, une mise en couleur a été utilisée afin de faciliter la lecture des résultats. Les teintes les plus foncées correspondent aux performances les plus élevées pour un indicateur donné, tandis que les teintes plus claires indiquent des performances plus faibles.

La coloration appliquée aux écarts-types permet quant à elle de visualiser la variabilité des performances entre les différents découpages apprentissage/test. Un écart-type faible indique une plus grande stabilité du modèle, tandis qu'un écart-type plus élevé traduit une variabilité plus importante selon les échantillons d'apprentissage.

4.3 | Modèles à base d'arbres

Une seconde famille de modèles reposant sur des structures d'arbres a été étudiée :

— arbre de décision classique ;
— boosting d'arbres ;
— forêt aléatoire ;
— préclassification suivie d'un arbre par cluster.

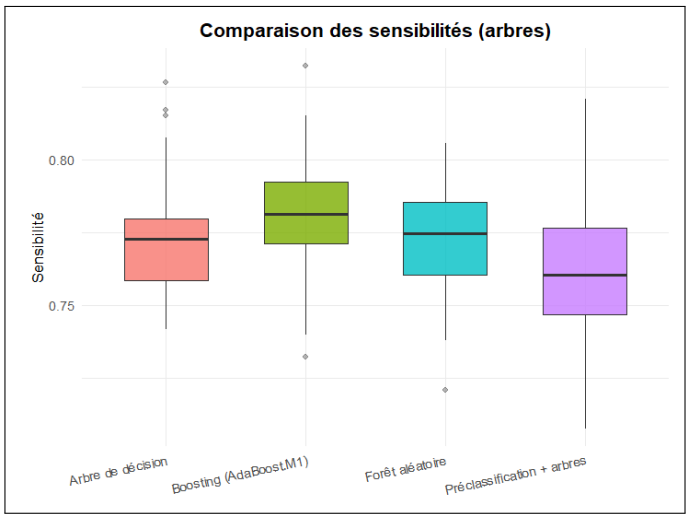

(a) Sensibilité

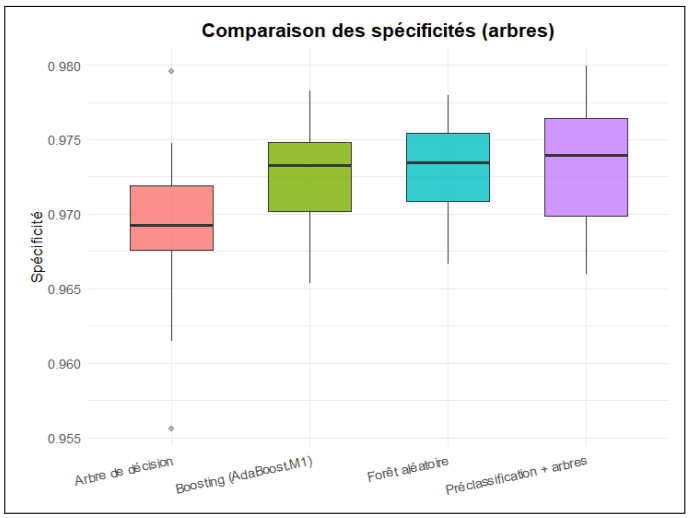

(b) Spécificité

Fig. 7 - Comparaison des performances des modèles à base d'arbres

Les résultats obtenus avec les modèles d'arbres présentent également des performances relativement proches. La sensibilité moyenne varie entre **0,76** et **0,78**, tandis que la spécificité moyenne se situe autour de **0,97**.

Le boosting apparaît comme la méthode la plus performante en termes de sensibilité, avec une moyenne proche de **0,782**. La spécificité la plus élevée est obtenue par la stratégie de préclassification suivie d'arbres, avec une valeur moyenne d'environ **0,973**.

L'arbre de décision simple présente des performances légèrement inférieures, ce qui est cohérent avec sa plus forte variance. Les méthodes d'ensemble telles que le boosting et la forêt aléatoire permettent généralement d'améliorer la robustesse des modèles.

Tableau récapitulatif des performances (arbres)

Modèle	Moyenne	Écart-type
sens_tree	0.772877	0.019760
spec_tree	0.969315	0.004062
sens_boost	0.781698	0.020416
spec_boost	0.972749	0.003171
sens_rf	0.771462	0.019128
spec_rf	0.973121	0.003039
sens_preclass	0.760708	0.023395
spec_preclass	0.973469	0.003937

Fig. 8 - Tableau récapitulatif des performances des modèles à base d'arbres

4.4 | Réseaux de neurones

Quatre architectures de réseaux de neurones ont été testées :

— une couche cachée composée de 5 neurones ;

— une couche cachée composée de 10 neurones ;
— deux couches cachées de taille (3,3) ;
— deux couches cachées de taille (3,2).

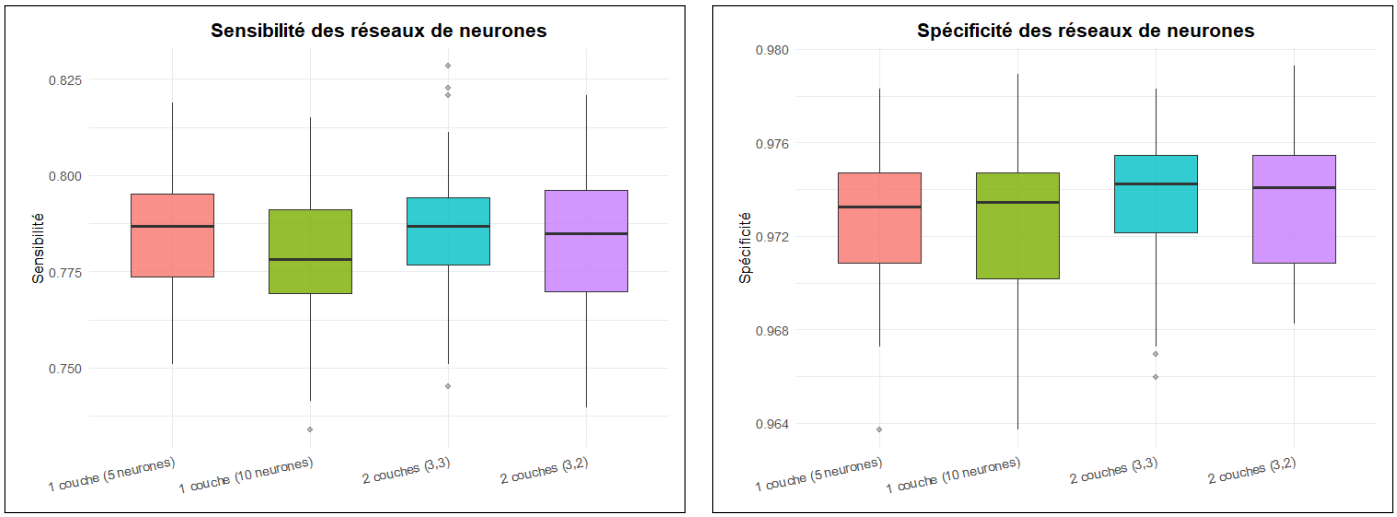

(a) Sensibilité (b) Spécificité

Fig. 9 - Comparaison des performances des réseaux de neurones

Les performances observées sont très proches d'une architecture à l'autre. La sensibilité moyenne varie entre **0,780** et **0,787**, tandis que la spécificité moyenne se situe entre **0,972** et **0,974**.

L'architecture la plus simple, comportant une seule couche cachée de 5 neurones, obtient la meilleure sensibilité moyenne (**0,787**). Les architectures plus complexes n'apportent pas d'amélioration nette des performances.

Ce résultat suggère que la relation entre les variables explicatives retenues et la variable cible ne nécessite pas un niveau élevé de complexité non linéaire dans ce contexte.

Tableau récapitulatif des performances (réseaux de neurones)

Architecture	Moyenne	Écart-type
sens_nn1	0.787123	0.016083
spec_nn1	0.972838	0.002978
sens_nn2	0.779717	0.017898
spec_nn2	0.972757	0.003515
sens_nn3	0.786226	0.018493
spec_nn3	0.973405	0.003063
sens_nn4	0.784670	0.017721
spec_nn4	0.973680	0.002878

Fig. 10 - Tableau récapitulatif des performances des réseaux de neurones

4.5 | Comparaison globale

Dans l'ensemble, les trois familles de modèles étudiées présentent des performances relativement proches. Les sensibilités moyennes se situent globalement entre **0,77** et **0,79**, tandis que les spécificités moyennes

se situent autour de **0,97**. Ces résultats indiquent que les modèles identifient correctement la grande majorité des individus non malades, tandis que la détection des cas malades reste légèrement plus difficile.

Quelques tendances peuvent néanmoins être observées :

— parmi les modèles linéaires, la préclassification améliore légèrement la sensibilité ;

— parmi les modèles à base d'arbres, les méthodes d'ensemble comme le boosting et la forêt aléatoire apparaissent plus robustes que l'arbre simple ;

— du côté des réseaux de neurones, l'augmentation de la complexité des architectures testées n'améliore pas significativement les performances.

Ces résultats suggèrent que l'information prédictive contenue dans les variables disponibles est relativement limitée. Les modèles plus complexes ne permettent pas d'obtenir une amélioration marquée des performances par rapport aux approches plus simples.

Dans ce contexte, des méthodes classiques comme la régression logistique ou les modèles d'arbres apparaissent déjà capables de capturer l'essentiel de l'information prédictive présente dans les données.

5 | Conclusion

Tout au long de leur carrière professionnelle, les agriculteurs sont exposés à une grande diversité de facteurs susceptibles d'influencer leur état de santé. Ces expositions résultent de la combinaison de nombreuses activités agricoles impliquant différents types de cultures, d'élevages et de conditions de travail. L'étude de ces expositions constitue donc un enjeu important pour mieux comprendre les déterminants professionnels pouvant être associés à l'apparition de certaines pathologies.

Dans ce travail, nous nous sommes appuyés sur les données issues de la cohorte AGRICAN afin d'étudier dans quelle mesure les profils de carrière agricole, décrits à travers des ratios de pratique des différentes activités, permettent de prédire la présence de la maladie étudiée.

Une première phase d'exploration des données a permis de mettre en évidence une forte hétérogénéité des pratiques agricoles ainsi qu'une distribution très asymétrique des variables, caractérisée par une concentration importante des observations au voisinage de zéro. Cette caractéristique traduit l'existence de profils professionnels spécialisés, certains agriculteurs se consacrant principalement à un nombre restreint d'activités.

Les valeurs strictement supérieures à 1, incompatibles avec la définition des ratios de carrière, ont été considérées comme des anomalies et transformées en valeurs manquantes. Ces dernières ont ensuite été imputées à l'aide d'une méthode basée sur l'Analyse en Composantes Principales, permettant de préserver les relations multivariées entre les variables tout en limitant la perte d'information.

Afin d'identifier les variables les plus pertinentes pour la prédiction, une procédure de présélection robuste a été mise en œuvre à l'aide d'une régression logistique associée à un ré-échantillonnage Bootstrap. Cette approche a permis de retenir les variables les plus stables et les plus informatives pour la phase de modélisation.

Plusieurs familles de modèles prédictifs ont ensuite été comparées : régression logistique, méthodes d'ensemble (bagging et boosting), modèles à base d'arbres, forêts aléatoires ainsi que différentes architectures de réseaux de neurones. Les performances ont été évaluées à l'aide de la sensibilité et de la spécificité sur 40 découpages aléatoires apprentissage/test afin d'obtenir une estimation robuste et stable des résultats.

Les performances obtenues montrent que les différentes approches présentent des résultats relativement proches. Les sensibilités moyennes se situent globalement autour de 0,78 tandis que les spécificités moyennes atteignent environ 0,97. Les méthodes d'ensemble et certaines architectures de réseaux de neurones obtiennent légèrement les meilleures performances, bien que les modèles plus simples comme la régression logistique capturent déjà une grande partie de l'information prédictive contenue dans les données.

Ces résultats suggèrent que les ratios de pratiques agricoles apportent une information pertinente pour la prédiction du risque de maladie, mais que cette information reste partielle et ne permet pas à elle seule d'expliquer l'ensemble des mécanismes impliqués dans la survenue de la pathologie.

Dans une perspective future, l'intégration de variables supplémentaires décrivant plus finement les expositions professionnelles, telles que l'intensité d'utilisation des produits phytosanitaires, les conditions de travail ou certains facteurs individuels, pourrait améliorer la capacité prédictive des modèles.

Plus largement, ce travail illustre l'intérêt de combiner différentes approches statistiques et méthodes d'apprentissage pour analyser des données complexes issues de cohortes épidémiologiques. La comparaison de plusieurs modèles permet non seulement d'évaluer leur performance prédictive, mais également de mieux comprendre le potentiel et les limites des données disponibles pour la prédiction des risques en santé publique.

Ainsi, cette étude met en évidence l'importance de l'analyse statistique exploratoire, de la sélection de variables et de la comparaison de différentes méthodes de modélisation pour l'étude de problématiques complexes en épidémiologie et en science des données.

6 | Annexe A : Principales fonctions et méthodes utilisées

— Détection des valeurs aberrantes

Les valeurs aberrantes ont été définies comme les valeurs strictement supérieures à 1, ce qui est incohérent avec la définition d'un ratio de carrière.

Ces observations ont été exportées à des fins de contrôle, puis remplacées par des valeurs manquantes avant imputation.

— Imputation des données manquantes

L'imputation a été réalisée à l'aide de la fonction `imputePCA()` du package `missMDA`. Cette méthode reconstruit les valeurs manquantes à partir des principales composantes de la structure multivariée.

— Analyse en composantes principales

L'ACP a été effectuée à l'aide de la fonction `PCA()` du package `FactoMineR`, avec visualisation des variables via `fviz_pca_var()` du package `factoextra`.

— Sélection de variables par Bootstrap

La présélection repose sur :
- la fonction `glm(..., family = binomial)` ;
- la procédure `stepAIC()` du package `MASS` ;
- 50 ré-échantillonnages Bootstrap.

Les cinq variables les plus souvent sélectionnées ont été retenues.

— Modélisation

Les modèles suivants ont été utilisés :
- régression logistique ;
- bagging et boosting (`adabag`) ;
- arbre de décision (`rpart`) ;
- forêt aléatoire (`randomForest`) ;
- réseaux de neurones (`neuralnet`).

— Évaluation des performances

Les performances ont été évaluées sur 40 splits apprentissage/test à l'aide de deux indicateurs :
- la sensibilité ;
- la spécificité.

Table des figures

1 Extrait des premières observations de la base de données 4
2 Description univariée des variables quantitatives 5
3 Courbes de densité des ratios de pratique agricole 6
4 Cercle des corrélations issu de l'Analyse en Composantes Principales 7
5 Comparaison des performances des modèles linéaires 9
6 Tableau récapitulatif des performances des modèles linéaires 10
7 Comparaison des performances des modèles à base d'arbres 11
8 Tableau récapitulatif des performances des modèles à base d'arbres 11
9 Comparaison des performances des réseaux de neurones 12
10 Tableau récapitulatif des performances des réseaux de neurones 12